

# **ESMA 5015: Examen 2**

Due on Abril 10, 2025

*Damaris Santana*

**Alejandro Ouslan**

## Contents

<b>1</b>	<b>Accept-Reject</b>	<b>3</b>
1.1	Por que es necesario que $a < \alpha$ y $b > \beta$	3
1.2	Para $a = \lfloor \alpha \rfloor$ , demuestre que $M$ ocurre en $x = \frac{\alpha - \lfloor \alpha \rfloor}{\frac{1}{\beta} - \frac{1}{b}}$	3
1.3	Para $a = \lfloor \alpha \rfloor$ , encuentre el valor optimo de $b$	3
<b>2</b>	<b>Implementación del algoritmo</b>	<b>4</b>
2.1	Describa un algoritmo <b>Accept-Reject</b> para generar una variable aleatoria con distribución $Gamma(3/2, 1)$	4
2.2	Algoritmo en Python	4
2.3	Grafique el histograma de la distribución obtenida sobreponiendo la distribución deseada	5
2.4	Estime $E[X^2]$ y construya la gráfica de la convergencia de los running means.	6
<b>3</b>	<b>Importance Sampling</b>	<b>7</b>
3.1	Estimador importance Sampling	7
3.1.1	$Cauchy(0, 1)$	7
3.1.2	$Normal(0, \frac{v}{v-2})$	7
3.1.3	$Exponencial(\lambda = 1)$	7
3.2	Estimador Monte Carlo	7
3.2.1	$Cauchy(0, 1)$	8
3.2.2	$Normal(0, \frac{v}{v-2})$	8
3.2.3	$Exponencial(\lambda = 1)$	8
3.3	Implementacion	8
3.4	Graficas	8

# 1 Accept-Reject

Suponga que desea generar variables aleatorias de una distribución  $\text{Gamma}(\alpha, \beta)$  donde  $\alpha$  no es necesariamente un entero. Decide usar el algoritmo **Accept-Reject** con la función candidata  $\text{Gamma}(a, b)$ .

## 1.1 Por que es necesario que $a < \alpha$ y $b > \beta$

Esto es para asegurar un buen candidato que se asurque lo mas posible a la función objetivo, esto es con el propósito de hacer el algoritmo mas eficiente.

## 1.2 Para $a = \lfloor \alpha \rfloor$ , demuestre que $M$ ocurre en $x = \frac{\alpha - \lfloor \alpha \rfloor}{\frac{1}{\beta} - \frac{1}{b}}$

$$\begin{aligned}
 x &= \sup \frac{f(x)}{g(x)} \\
 &= \sup \frac{\text{Gamma}(\alpha, \beta)}{\text{Gamma}(a, b)} \\
 &= \sup \frac{\frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{x}{\beta}}}{\frac{1}{\Gamma(a)b^a} x^{a-1} e^{-\frac{x}{b}}} \\
 &= \left( \frac{\frac{1}{\Gamma(\alpha)\beta^\alpha}}{\frac{1}{\Gamma(a)b^a}} \cdot \frac{x^{\alpha-1}}{x^{a-1}} \cdot \frac{e^{-\frac{x}{\beta}}}{e^{-\frac{x}{b}}} \right) \frac{d}{dx} \\
 &= \left( x^{\alpha-a} \cdot e^{\frac{x}{b} - \frac{x}{\beta}} \right) \frac{d}{dx} \\
 &= \left( x^{\alpha-1} e^{\frac{x}{b} - \frac{x}{\beta}} \right) \left( \left[ \frac{1}{\beta} - \frac{1}{b} \right] + (\alpha - a)x^{-1} \right) = 0 \\
 &= \left[ \frac{1}{\beta} - \frac{1}{b} \right] + (\alpha - a)x^{-1} = 0 \\
 &= \left[ \frac{\alpha - a}{\frac{1}{\beta} - \frac{1}{b}} \right]_{a=\lfloor \alpha \rfloor} \\
 &= \frac{\alpha - \lfloor \alpha \rfloor}{\frac{1}{\beta} - \frac{1}{b}}
 \end{aligned}$$

## 1.3 Para $a = \lfloor \alpha \rfloor$ , encuentre el valor optimo de $b$

$$Mode_{target} = Mode_{candidate}$$

$$(\alpha - 1)\beta = (a - 1)b$$

$$b = \frac{(\alpha - 1)\beta}{a - 1}$$

Como  $\alpha - 1 \approx \alpha$  y  $a - 1 \approx a$

$$b = \frac{\alpha\beta}{a}$$

## 2 Implementación del algoritmo

### 2.1 Describa un algoritmo Accept-Reject para generar una variable aleatoria con distribución $\text{Gamma}(3/2, 1)$

$$\begin{aligned} M &= \frac{f(x)}{g(x)} \\ &= \frac{f(x)}{g(x)} = \frac{\frac{2}{\sqrt{\pi}} x^{\frac{1}{2}} e^{-x}}{x e^{-x}} \\ &= \frac{2}{\sqrt{\pi}} \cdot \frac{1}{\sqrt{x}} \\ &= \frac{2}{\pi} \end{aligned}$$

1. Generar un número  $Y$  de la distribución  $\text{Gamma}(2, 1)$ .
2. Generar un número uniforme  $U \sim U(0, 1)$
3. Si  $U \geq \frac{Y}{Mg(Y)}$
4. Repetir el proceso hasta aceptar un valor

### 2.2 Algoritmo en Python

#### Implementación de python

```
import numpy as np

# Función de densidad de la distribución objetivo (Gamma(3/2, 1))
def f(x):
    return (2 / np.sqrt(np.pi)) * np.sqrt(x) * np.exp(-x)

# Función de densidad de la distribución candidata (Gamma(1, 2))
def g(x):
    return x * np.exp(-x)

# Algoritmo de aceptación y rechazo
def accept_reject(n, seed=787):
    # Semilla para la generación de números aleatorios
    rng = np.random.default_rng(seed=seed)
    samples = []
    M = 2 / np.sqrt(np.pi)

    while len(samples) < n:
        # Paso 1: Generar una muestra de la distribución candidata (Gamma(1, 2))
        Y = rng.gamma(1, 2)

        # Paso 2: Generar una variable aleatoria uniforme U
        U = rng.uniform(0, 1)

        # Paso 3: Aceptar o rechazar
```

```
        if U <= f(Y) / (M * g(Y)):
            samples.append(Y)

    return np.array(samples)

if __name__ == "__main__":
    n_samples = 10000
    samples = accept_reject(n_samples)
```

### 2.3 Grafique el histograma de la distribución obtenida sobreponiendo la distribución deseada

#### Implementacion de python

```
from accept import *
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import gamma

def main(n: int):
    samples = accept_reject(n)

    # Traficar el histograma
    x = np.linspace(0, 10, 1000)
    plt.hist(
        samples,
        bins=50,
        density=True,
        alpha=0.6,
        color="b",
        label="Histograma (muestras)",
    )
    plt.plot(x, gamma.pdf(x, 3/2, scale=1), 'r-', label='Distribución Gamma(3/2, 1)')

    plt.xlabel("x")
    plt.ylabel("Densidad")
    plt.legend()
    plt.title("Histograma de la Distribución Generada vs. Distribución Objetivo")
    plt.show()

if __name__ == "__main__":
    n_samples = 10000
    main(n_samples)
```




Figure 1: Histograma de la la gama simulada

2.4 Estime  $E[X^2]$  y construya la gráfica de la convergencia de los running means.

$$\begin{aligned}
 E[X^2] &= \alpha(\alpha + 1)\beta^2 \\
 &= \frac{3}{2}\left(\frac{3}{2} + 1\right) = 3.75
 \end{aligned}$$

title

```

# Estimar  $E[X^2]$  y construir la gráfica de la convergencia de los "running means"
running_means = np.cumsum(samples) / np.arange(1, n_samples + 1)

# Graficar la convergencia
plt.plot(running_means, label="Running Mean")
plt.axhline(y=np.mean(samples), color="r", linestyle="--", label="Media Estimada")
plt.xlabel("Número de Muestras")
plt.ylabel("Running Mean")
plt.legend()
plt.title("Convergencia del Running Mean a la Media Estimada")
plt.show()

# Estimación de  $E[X^2]$ 
E_X2_estimated = np.mean(samples) + np.mean(samples) ** 2
print("Estimación de  $E[X^2]$ :", E_X2_estimated)

```




Figure 2: Histograma de la variable aleator

### 3 Importance Sampling

Usando Importance Sampling estime  $E_f \left[ \frac{X^5}{1+(X-3)^2} I[X \geq 0] \right]$ , donde  $f$  es la distribución  $t$  con  $v = 12$  Utilice las siguientes  $g$ :

1.  $Cauchy(0, 1)$
2.  $Normal(0, \frac{v}{v-2})$
3.  $Exponencial(\lambda = 1)$

#### 3.1 Estimador importance Sampling

Para cada una de estas distribuciones presente el estimador que corresponde a la sumatoria definida por el metodo de **Importance Sampling** y que converge al valor esperado de interes

**3.1.1**  $Cauchy(0, 1)$

**3.1.2**  $Normal(0, \frac{v}{v-2})$

**3.1.3**  $Exponencial(\lambda = 1)$

#### 3.2 Estimador Monte Carlo

Para cada uno presente el estimador que corresponde a la sumatoria definida por el metodo de Integracion Monte Carlos y que converge al valor esperado de interes.

**3.2.1** *Cauchy*(0, 1)

**3.2.2** *Normal*(0,  $\frac{v}{v-2}$ )

**3.2.3** *Exponencial*( $\lambda = 1$ )

### **3.3 Implementacion**

### **3.4 Graficas**

Construya un asola graica y presente la convergencia de los running menas para los cuatro estimadores. Compare la varianza empirica de los cuatro estimadores