

ESMA 5015: Accept Reject

Alejandro Ouslan

Spring 2025

Contents

1	notes for 2025-03-06	1
2	Consideren un algoritmo Accept-Reject para simular $X \sim N(0, 1)$	2
2.1	theory	3
2.2	algorithm	3
2.3	steps	3
2.4	algorithm	3
3	Generar una $X \sim Beta(\alpha, \beta)$	4
3.1	algorithm	4
4	Ejemplo generar $X \sim Beta(\alpha = 2.7, \beta = 6.3)$	4
4.1	algorithm	4
5	Assignment	5
6	Bayesian Inference	5
6.1	Ejemplo	5
6.1.1	Frecuentista	5
6.1.2	Bayesiana	5
6.1.3	Calculation	5
6.2	Assignment	6
7	Markor Chain Monte Calro (MCMC)	6
7.1	Metropolis Hating	6
7.2	Algorithmo	6
7.2.1	Ejecicio de practica	7

1 notes for 2025-03-06

$$E(w) = \alpha\beta$$

$$w \sim gamma(\alpha, \beta) \quad var(w) = \alpha\beta^2$$

$$\begin{aligned}
F_y(g) &= \frac{1}{2}e^{-y} + \frac{1}{2}ye^{-y} \\
E[y] &= \int_0^\infty y f_y(y) dy \\
&= \frac{1}{2}E[y_1] + \frac{1}{2}E[y_2] \\
y_1 &\sim \text{gamma}(1, 1) \\
y_2 &\sim \text{gamma}(2, 1) \\
&= \frac{1}{2}1 + \frac{1}{2}2 \\
&= \frac{3}{2}
\end{aligned}$$

$$\begin{aligned}
\text{var}(y) &= E[y^2] - E[y]^2 \\
E[y^2] &= \int_0^\infty y^2 f_y(y) dy \\
&= .5E[y_1^2] + .5E[y_2^2] \\
&= \frac{1}{2}2 + \frac{1}{2}6 \\
&= 4
\end{aligned}$$

$$\begin{aligned}
E[y_1^2] &= \text{var}(y_1) + E[y_1]^2 \\
&= 1 + 1^2 \\
&= 2
\end{aligned}$$

$$\begin{aligned}
E[y_2^2] &= \text{var}(y_2) + E[y_2]^2 \\
&= 2 + 2^2 \\
&= 6
\end{aligned}$$

$$\begin{aligned}
&= 4 - \frac{3^2}{2} \\
&= 4 - \frac{9}{2} \\
&= \frac{7}{2}
\end{aligned}$$

2 Consideren un algoritmo Accept-Reject para simular $X \sim N(0, 1)$

1. usando $Y \sim \text{cauchy}(0, 1)$

$$F_Y(y) = \frac{1}{\pi} \frac{1}{1 + y^2} \quad y \in \mathbb{R}$$

2. usando $Y \sim \text{double-exponential}(0, 1)$

$$f_Y(y) = \frac{1}{2}e^{-|y|} \quad y \in \mathbb{R}$$

2.1 theory

1. calculate $M = \sup_x \frac{f_X(x)}{f_Y(y)}$

$$\begin{aligned}
 &= \sup_x \frac{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}}{\frac{1}{\pi} \frac{1}{1+x^2}} \\
 &= \sup_x \frac{\pi}{\sqrt{2}} e^{-x^2/2} (1+x^2)
 \end{aligned}$$

sea $h(x) = e^{-x^2/2}(1+x^2)$

$$\begin{aligned}
 \frac{dh(x)}{dx} &= -xe^{-x^2/2}(1+x^2) + e^{-x^2/2}2x \\
 &= \vdots \\
 &= -xe^{-x^2/2}(x^2-1)
 \end{aligned}$$

$$\frac{dh(x)}{dx} = 0 \Rightarrow x = 0, \pm 1 \text{ puede demostrar que el máximo ocurre en } x = \pm 1 \Rightarrow M = \frac{\pi\sqrt{\pi}}{\sqrt{2}} e^{-1/2} = 1.52$$

2.2 algorithm

1. simular $Y \sim \text{cauchy}(0, 1)$ y $U \sim U(0, 1)$ independientes.
2. si

$$\begin{aligned}
 U &< \frac{f_X(Y)}{M f_Y(Y)} \\
 &= \frac{1}{\sqrt{2\pi}} e^{-1/2} \frac{\sqrt{\pi}}{\sqrt{\pi}} (1+Y^2) \\
 &= \frac{1}{2} (1+Y^2) e^{\frac{-Y^2+1}{2}}
 \end{aligned}$$

aceptar $X = Y$

3. si no, regresar a paso 1.

2.3 steps

- 1.

$$\begin{aligned}
 M &= \sup_x \frac{f_X(x)}{f_Y(y)} = \sup_x \frac{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}}{\frac{1}{2} e^{-|x|}} \\
 &= \sup_x \frac{\sqrt{2}}{\sqrt{\pi}} e^{-x^2/2+|x|}
 \end{aligned}$$

$$h(x) = \ln \left(e^{-x^2/2+|x|} \right)$$

$$\frac{dh(x)}{dx} = \frac{d}{dx} \left(-\frac{x^2}{2} + |x| \right) = \begin{cases} -x-1 & x < 0 \\ -x+1 & x > 0 \end{cases}$$

$$\frac{dh(x)}{dx} = 0 \Rightarrow x = \pm 1$$

debe demostrar que el supremo ocurre en $x = \pm 1$

2.4 algorithm

1. $M = \frac{\sqrt{2}}{\sqrt{\pi}} e^{-1/2+1} = 1.31$
2. simular $Y \sim \text{double-exponential}(0, 1)$ y $U \sim U(0, 1)$ independientes.

3. si

$$U < \frac{f_X(Y)}{M f_Y(Y)} = e^{\frac{-y^2}{2} + |y| - 1/2}$$

entonces aceptar $X = Y$

4. si no, regresar a paso 2.

3 Generar una $X \sim \text{Beta}(\alpha, \beta)$

Donde $0 < x < 1$ y $\alpha, \beta > 0$

Utilizar $y \sim U(0, 1)$.

$$\begin{aligned} M &= \sup_x \frac{f_X(x)}{f_Y(y)} = \frac{\frac{\gamma(\alpha+\beta)}{\gamma(\alpha)\gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}}{1} \\ h(x) &= \ln(X^{\alpha-1} (1-x)^{\beta-1}) \\ \frac{dh(x)}{dx} &= \frac{\alpha-1}{x} - \frac{\beta-1}{1-x} \\ \frac{dh(x)}{dx} = 0 &\Rightarrow x = \frac{\alpha-1}{\alpha+\beta-2} \text{ y } \beta! = 1, \alpha! = 1 \end{aligned}$$

puede demostrar que en esta X OCURRE UN maximo

3.1 algorithm

1. Generar $y \sim U(0, 1)$ y $U \sim U(0, 1)$ independientes.

2. Si

$$u < \frac{f_X(y)}{M f_Y(y)} = \frac{\frac{\gamma(\alpha+\beta)}{\gamma(\alpha)\gamma(\beta)} y^{\alpha-1} (1-y)^{\beta-1}}{\frac{\gamma(\alpha+\beta)}{\gamma(\alpha)\gamma(\beta)} \frac{\alpha-1}{\alpha+\beta-2} \alpha^{-1} (1 - \frac{\alpha-1}{\alpha+\beta-2})^{\beta-1}}$$

define $X = y$

3. si no, regresar a paso 1.

4 Ejemplo generar $X \sim \text{Beta}(\alpha = 2.7, \beta = 6.3)$

$M = 2.6667444$ que ocurre en $x = \frac{2.7-1}{2.7+6.3-2} = 0.2428$

4.1 algorithm

1. Generar $y \sim U(0, 1)$ y $U \sim U(0, 1)$ independientes.

2. Si

$$u < \frac{f_X(y)}{M f_Y(y)} = \frac{\frac{\gamma(\alpha+\beta)}{\gamma(\alpha)\gamma(\beta)} y^{\alpha-1} (1-y)^{\beta-1}}{2.666744}$$

Define $X = y$

3. si no, regresar a paso 1.

5 Assignment

para la cauchy y double double-exponential

1. Mathematics
2. Algorithm Implementar codigo y grafica con la distribucion deseada

$$P(x \leq y) = \int_{-\infty}^x f(t)dt$$

6 Bayesian Inference

Accept y Metropolis Hasting (topico de la proxima clase) surgen naturalmente en estadísticas Bayesianas. En el Analisis Bayesiano además de especificar el modelo de los datos observados $X = x_1, x_2, \dots, x_n$ dado un vector de parámetros desconocidos θ definido por $f(x|\theta)$, se define θ como una variable aleatoria que tiene una distribución a priori $\pi(\theta)$. El Conocimiento de θ se actualiza con el conocimiento que se obtiene de los datos basados en la inferencia concerniente a θ . en la distribución posterior definida por

$$\pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{\int_{\Theta} f(x|\theta)\pi(\theta)d\theta} \quad \text{Teorema de Bayes}$$
$$\pi(\theta|x) \propto f(x|\theta)\pi(\theta)$$

6.1 Ejemplo

x_1, x_2, \dots, x_n iid $Bernulli(\theta)$

6.1.1 Frecuentista

IC de $(1 - \alpha)100\%$ para θ

$$\hat{\theta} \pm z_{\alpha/2} \sqrt{\frac{\hat{\theta}(1 - \hat{\theta})}{n}}$$

6.1.2 Bayesiana

$$f(x_1, x_2, \dots, x_n|\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}$$
$$\pi(\theta|x_1, x_2, \dots, x_n) = \frac{\theta^{\sum x_i} (1 - \theta)^{n - \sum x_i} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}}{\int_0^1 \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} d\theta}$$

En este caso la distribución a priori es conjugada con $f(x|\theta)$ porque $\pi(\theta|x)$ pertenece a la misma familia de la distribución a priori.

6.1.3 Calculation

$$E[\theta|x_1, x_2, \dots, x_n] = \frac{\sum x_i + \alpha}{\sum x_i + \alpha + n - \sum x_i + \beta}$$
$$= \frac{\sum x_i + \alpha}{n + \alpha + \beta}$$

Si n es mucho mayor que $\alpha + \beta$ el promedio posterior se inclina hacia el promedio muestral

6.2 Assignment

Considere $X_1, X_2, \dots, X_n; \sigma^2$ conocido y la distribución a priori

$$\pi(\theta) = N(\mu_0, \tau^2)$$

Demuestre que

$$\pi(\theta|x_1, x_2, \dots, x_n) \propto N\left(\frac{n\hat{x} + \frac{\mu}{\tau^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}, \frac{1}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}\right)$$

7 Markor Chain Monte Calro (MCMC)

Definition 1. Un metodo MCMC para simular de una distribución F es cualquier metodo que produzca una cadena de MARKOV erogodica X_N cuya distribución estacionari es F

Elejemplos dde estos metodos:

1. Metropolis-Hastings
2. Gibbs Sampling
3. Data Augmentation Algorithm

Tipicamnet ese descartan las variables iniciales de la cadena para "asegurarce" seleccionarl las que tiene la distribución deseada. (que converga la distribución)

7.1 Metropolis Hating

Vimos accept-reject . Y sea que es difícil calcular una distribución cadidata que resulte en una M adecuada ($M > \infty$, of facil de calcular), Metropolis Hatings ofrece una alternativa para simular de una distrobucion F

7.2 Algorithmo

1. Sea $X \sim f_x(x)$ target
2. Sea $y \sim f_y(y)$ candidate
3. Genera $y \sim f_y(y)$. Define $Z_0 = y$ para $i = 1, 2, 3, \dots$
4. Genera $U \sim U(0, 1)$
5. Define $P_i = \min\left\{\frac{f_x(y_i)f_y(z_{i-1})}{f_y(y_i)f_x(z_{i-1})}, 1\right\}$
6. $Z_i = \begin{cases} y_i & \text{si } u_i \leq P_i \\ z_{i-1} & \text{si } u_i > P_i \end{cases}$
7. ENtonces, $i \rightarrow \infty$ Z_i converge en distribución a la distribución $F_x(X)$
 - Convergencia en distribución. una secuencia x_1, x_2, \dots converge en distribución a una variable alatoria X si $\lim_{n \rightarrow \infty} F_{x_n}(x) = F_X(X)$ para todas los punetos desde F_X es continua
 - Este algoritmo produce lo que se conoce como una cadena de markov que converge a $f_x(x)$ y ino una variable con distribución $f_x(x)$ y no una variable alatoria con distribución $f_x(x)$ como comolo hace accept-reject.
 - Se destaca las variables alatoria iniciales de la cadena para "asegurar" que la variable alatoria escogida tiene distribución $F_x(x)$
 - La variable aleatoria generada no simula idependientes n to ∞

- Con los metodos MCMC tenemos una cadena acodada y se cumple un resultado abnalogo a la ley de ldo numeros grandes por lo que

$$\frac{1}{n} \sum_{i=1}^n g(x_i) \rightarrow E[g(X)]$$

aunque X_i no son idependients.

- Pero hubiera necesidad de idepenencia par una aplicaciciopn particualr una alternatica es generar xadena paralela hasta la convergencia yh toma el ultimo elemento de cada uno.

7.2.1 Ejecicio de practica

Compara Accept-Reject con Metropolis Hasting en la estimaxion de $E[x^2]$ cuando $X \sim \Gamma(\alpha, 1)$ usando $Y \sim \Gamma(|\alpha|, \frac{\alpha}{\alpha_{\mathbb{R}^+}})$

Definition 2. *Un aseguancia x_0, X_1, \dots, X_n de variable aleatoria es una cadenan de Markov si*

$$P(X_n \in A | x_0, x_1, \dots, x_{n-i}) = P(X_n \in A | x_{n-1})$$